

QGIS 플러그인 5종을 만들고 그 위에 로컬 LLM을 올렸다

공유재산 실태조사 업무를 플러그인으로 자동화하고, 그 도구들을 12단계 파이프라인으로 묶은 뒤 로컬 LLM을 붙였다. 목표는 QGIS를 자연어로 제어하는 전용 모델과 사내 프로젝트 전용 LLM이다. 다만 LLM이 지는 자리에서는 쓰지 않았고, 그렇게 판단한 근거와 수치를 아래에 정리했다.

신명호 AI 엔지니어 / LLM 파이프라인 Python · Ollama · PyQGIS 2026.07

LAYER 3	LLM 자연어→PyQGIS 에이전트 · RAG 검색 · 모델 평가 하네스
LAYER 2	파이프라인: 오케스트레이터 12단계 DAG · QGIS 소켓 브릿지 · 업무 DB
LAYER 1	도구: QGIS 플러그인 5종 정합 · 캡처 · 순회 · 지리참조 · 현장확인
규율	측정 먼저 모든 계층에서 LLM과 규칙과 사람 중 무엇이 이기는지 재고 결정한다

아래로 갈수록 먼저 만든 것이다. LLM은 마지막에 올렸다. 제어할 도구가 없으면 자연어로 시킬 일 자체가 생기지 않기 때문이다.

Layer 1 도구: 직접 만든 QGIS 플러그인

전량 실무 투입 · 사내 배포

전부 실제 업무에서 막힌 지점에서 출발했다. 다섯 개 모두 팀이 쓰고 있고 사내 플러그인 저장소로 배포된다. 붉은 표시가 붙은 줄은 만들면서 직접 밟은 함정이다.



아래 도구들이 실제로 만들어내는 산출물이다. 같은 필지를 두 배경에서 렌더했다. 왼쪽은 드론 사진을 지리참조한 TIF, 오른쪽은 위성영상이라 출처가 서로 다른데 **지적 경계선이 같은 자리에 놓인다**. 정합이 어긋났다면 두 장에서 경계가 벌어지므로, 이 비교 자체가 검수 수단이 된다. 노란 지번이 조사 대상 필지인데, 작고 얇은 대상이 거대한 이웃 필지에 밀려 라벨이 사라지던 문제를 우선순위 규칙으로 고친 뒤의 결과다. 발주처와 사업명은 익명 처리했다.

JPG to GeoTIFF: 드론 사진 지적 정합

v1.47

신규 제작

드론 원본 JPG의 XMP(GPS, 짐벌 Yaw/Pitch, 상대고도)를 읽어 위성영상과 대조하고, 지적도에 정합된 GeoTIFF로 배치 변환한다.

- 매칭 경로를 **LoFTR 1순위, SIFT 풀백** 구조로 재편했다. SIFT는 불기만 하면 정확한데 특징이 빈약한 논밭에서는 대부분 못 붙는다. 그 구멍을 LoFTR가 메운다
- 게이트를 통과한 사진은 개별 확정하고, 미달분은 2패스 이웃 앵커링, 비행 중앙값, NCC 순으로 단계적으로 회수한다
- 위성 해상도 z19는 NCC에 쓰면 해롭고 SIFT에 쓰면 유리하다 (특징점 **14개**에서 **7,000개** 이상으로). 어느 쪽이 맞다고만 적어두면 반대 상황에서 틀린 판단을 하게 되므로 조건을 붙여 정리했다
- 센서폭 역산 오류로 GSD가 계통적으로 **4%** 과대했다. 그런데 자동보정이 매 장 이 편향을 상쇄해서 산출물은 정상으로 보였고, 자동보정이 걸리지 않은 사진에만 오차가 남아 있었다. 결과가 멀쩡해 보인다고 검증이 된 것은 아니었다
- 설정 경로가 어긋나 LoFTR가 빠진 채로 1시간을 돌았다. 남은 흔적은 경고 한 줄이었고 배치는 "성공"으로 끝났다. 확정률이 3분의 1로 떨어져도 실패로 잡히지 않는다
- 실측 후 폐기한 접근 **6종**을 근거와 함께 문서로 남겨 같은 길을 다시 파지 않게 했다

19% → 60% 1패스 자동 확정률	4% 제거한 GSD 계통 편향	6종 폐기 근거를 문서화한 접근
--------------------------------	----------------------------	-----------------------------

실태조사표를 읽어 필지 단위로 근경, 원경, 위성, 지적 4컷을 640×480 규격으로 일괄 렌더한다. 성과품에 들어가는 필지 사진이 여기서 나온다.

- 정합에 실패해 33km 크기로 워프된 TIF 한 장이 전 필지의 후보로 잡히고 있었다. 폴더 GSD 중앙값 대비 8배를 넘는 영상을 색인 진입 전에 **사전 필터**로 걸러냈다
- 작고 얇은 대상 필지의 지번 라벨이 거대한 이웃에 밀려 탈락했다. 데이터와 기하는 정상이었고 순수하게 라벨 배치 문제였다. 대상에 우선순위와 항상표시 속성을 주어 해결했다
- 넓은 범위를 캡처하면 주택가 잔라벨 수백 개가 뭉쳤다. 최소 피쳐 크기 기준으로 디클러터를 걸어 축척은 그대로 두고 라벨만 줄였다
- 온캔버스 레이어에 렌더러를 걸면 스냅 인덱스와 충돌해 QGIS 프로세스가 종료된다. **클론에 스타일을 적용해 렌더하면** 충돌이 없고 원복도 필요 없다
- 편집 중인 레이어에서는 필터가 조용히 실패한다. 필터가 걸리지 않은 채 렌더돼 이웃 필지까지 붉게 찍혔다. 이후 규칙 기반 렌더러 필터로만 처리한다

80%

사전 필터로 제거한 표본 오염

4컷

필지당 자동 산출 규격

PNU 목록을 불러와 필지를 하나씩 이동하며 확인하고 결과를 기록하는 도구다. v7에서 순회 전용 패널과 설정 콘솔 두 개로 재설계했다.

- 사업마다 달라지는 설정을 QGIS 프로젝트 파일 옆 **사이드카**로 옮겼다. 팀원은 프로젝트만 열면 그 사업 설정으로 동작하고, 공유 드라이브에 올리면 설정이 폴더에 실려 간다
- 이전 사업의 레이어명이 남아 있으면 강조가 통째로 건너뛰어졌다. 증상은 세 가지로 보였지만 원인은 하나였고, 레이어 역할을 자동 해석하도록 고쳤다
- 팀 PC에서 첫 실행에 QGIS가 멈췄다. UI 스레드의 폴더 탐색이 공유 드라이브에서 무제한으로 걷고 있었는데, 내 PC는 로컬이라 재현되지 않았다. **400**디렉터리와 **2.5**초 예산제로 막았다. 로컬에서 빠르다고 NAS에서 빠르지 않다
- 대상 필지 테두리가 이웃 지적선에 덮이는 버그를 "규칙 순서" 문제로 고쳤는데 오진이었다. 규칙 기반 렌더러는 규칙 순서가 아니라 **피쳐 id 순서**로 그린다. 심볼 레벨을 지정해 다시 풀었다
- 배포 전 게이트로 병렬 코드리뷰를 돌려 검증된 결함 **8**건을 일괄 수정했다. 팀원 설정 유실과 필드 변경 시의 조용한 매칭 실패가 여기서 잡혔다

오픈소스 플러그인(FreehandRasterGeoreferencer)을 한글화하고, 자동 정합이 실패한 사진을 사람이 직접 맞추는 도구로 확장했다. 논발이나 저고도, 망원 사진은 자동 정합도 자동 검증도 원리적으로 불가능하다. 이 도구가 그 구간을 맡는다.

- 12개 파일을 한글화하고 Dock 패널과 단축키 설정 대화상자를 새로 구현했다
- 지상기준점을 캔버스에서 찍고 끌고 지우는 **GCP 캡처**를 붙였다. Helmert 최소제곱 닫힌해를 직접 구현해 잔차와 RMSE를 산출하고, QGIS에 의존하지 않는 순수 로직으로 분리해 단위테스트 **27**건을 붙였다
- 원본에 좌표를 쓸 때 픽셀을 다시 굵지 않고 GeoTIFF 내부 geotransform만 갱신한다. 리샘플링이 없으므로 화질 손실이 발생하지 않는다
- 월드파일만 쓰면 GDAL 우선순위에서 내부 geotransform이 이겨 무시된다. 월드파일은 픽셀 중심을, GDAL은 모서리를 기준으로 삼기 때문에 반 픽셀 보정도 필요했다
- "단축키가 안 먹는다"의 원인은 해제 누락이었다. 리로드할 때마다 액션이 쌓여 한 세션에 **212**개까지 갔고, 같은 단축키가 중복돼 전부 무력화됐다

카카오 로드뷰: 현장 확인 단축

v0.1

신규 제작

지도 캔버스에서 필지를 클릭하면 그 위치의 로드뷰가 브라우저 탭으로 열린다. 기능은 작지만 현장 확인이 필요할 때마다 지도를 벗어나지 않아도 된다.

사내 플러그인 저장소

배포 인프라

위 도구들을 팀에 전달하는 경로다. 공유 드라이브에 zip을 넣고 스크립트를 한 번 돌리면 저장소 목록이 갱신되고, 팀원은 QGIS 플러그인 관리자에서 그대로 설치하고 업데이트한다.

Layer 2 파이프라인: 도구를 하나로 묶다

회귀 테스트 287건

도구가 늘어날수록 지금 어디까지 했는지가 사람 머릿속에만 남았다. 인수인계도 재현도 되지 않는 상태였다. 업무 12단계를 상태 기반 DAG로 정의하고 도구들을 단계 핸들러로 흡수했다.

- 고객 컨펌, 현장조사 외주, 납품처럼 사람이 개입해야 넘어가는 단계가 중간에 박혀 있다. 한 번에 끝나는 작업이 없으므로 단계형 설계가 필수였다
- 폴더 번호와 레이어명이 사업마다 다르다. 완료 조건을 하드코딩하지 않고 프로젝트 메타에서 읽으며, 산출물의 존재와 개수는 자동 검증한다
- 도구 5종을 핸들러로 연결했다. 기초조사 생성, 지적도 매핑, 필지 캡처, 의견 생성, 성과품 제작이다
- 인수 확인과 대상지 추출은 헤드리스로 다시 짜서 QGIS 의존을 없앴다. 대장과 지적도 매칭률은 **99%**였다
- 종료 코드만 보고 성공을 판정하던 단계가 **0/134** 변환 실패를 "완료"로 보고하고 있었다. 실제 산출 개수를 전후로 대조하도록 고쳤다. 주입 테스트로는 안 잡히고 통합 실행에서만 드러나는 결함이다
- 실제 사업에 처음 돌리자 실데이터에서만 나오는 결함 **3건**이 곧바로 나왔다

QGIS 소켓 브릿지

외부 프로세스 → 실행 중 QGIS

QGIS 플러그인은 QGIS 안에서만 살고 파이프라인은 밖에 있다. 실행 중인 QGIS의 소켓 프로토콜을 해석해 바깥에서 코드를 주입하는 브릿지를 만들어 둘을 연결했다. Layer 3의 LLM 에이전트도 같은 통로를 쓴다.

업무 데이터베이스

SQLite → NAS MariaDB

- 흩어져 있던 사업 산출물을 **7개** 테이블로 스키마화하고 NAS로 이관했다. 조사 의견 **197,170**행을 적재했다
- 임베딩은 고유한 **4,779**종에만 걸어 비용을 **41**배 줄였다. 같은 문자열을 행마다 다시 임베딩할 이유가 없다
- 모든 적재 스크립트의 기본 동작을 dry-run으로 두었다. 최초 실행이 적재 버그 **3건**을 잡았다
- 야간 자동 수집 배치는 먹등이라 새로 완결된 사업만 주워담고, 운영 비용이 들지 않는다
- 이관 대상 목록이 하드코딩돼 있어서 "이관 완료"를 찍으면서 **22만**행을 빠뜨릴 뻔했다. 이후로는 테이블별 행수를 양쪽에서 대조한다
- 개인정보 경계를 코드로 분리했다. 의견 수집기는 소재지와 성명을 읽지 않는다

사내 전용 LLM을 만드는 것이 목표다. 외부 API를 호출해서는 그 목표에 다가갈 수 없으므로 처음부터 로컬 모델을 기반으로 간다. 그래서 무엇을 쓸지 고르기 전에 무엇이 부족한지 재는 일부러 했다.

자연어를 PyQGIS로 옮기는 실행 에이전트

Ollama · 소켓 브릿지

GIS 조작은 PyQGIS 코드 작성을 요구해서 비개발 인력이 접근할 수 없었다. 자연어 한 줄로 QGIS를 조작하게 만드는 것이 목표였다.

- 첫 시도는 전부 import 누락으로 실패했다. 실행 래퍼가 **프리앰블을 주입**하자 실행 실패 자체가 사라졌다. 모델은 import를 신뢰성 있게 하지 않으므로, 프롬프트를 고칠 게 아니라 배관을 고쳐야 했다. 막고 있던 것은 모델 성능이 아니라 실행 스캐폴딩이었다
- 남은 로직 오답은 큐레이션 few-shot으로 교정했다. 실무 벤치마크가 **7/8**에서 **8/8**이 됐다
- 에러가 나면 트레이스백을 되먹여 자가 수정하고, 데이터를 변경하는 코드는 휴리스틱으로 감지해 확인 게이트를 통과시킨다
- 모든 실행이 요청과 코드와 결과 쌍으로 자동 축적된다. 쓸수록 파인튜닝 코퍼스가 쌓이는 구조다
- Layer 1에서 밟았던 함정을 그대로 예시로 심었다. 클론 누락이나 CRS 변환 같은 것들인데, 심어두면 에이전트가 같은 실수를 하지 않는다

코퍼스는 영어 기술문서인데 질의는 한국어다. 교차언어 검색이라 모델의 다국어 정렬 능력이 결과를 좌우한다.

- 먼저 청킹 재설계를 A/B로 검증했고 변별력이 움직이지 않았다. 문제가 청킹에 있지 않다는 것을 확인한 뒤에 모델을 바꿨다
- 임베딩 모델 3종을 비교하고 bge-m3를 채택했다. 판단 기준은 절대 유사도가 아니라 1위와 평균의 간격이었다. 간격이 좁으면 유사도가 높게 나와도 임계값으로 무관한 결과를 자를 수 없다
- 프레임워크를 쓰지 않고 **SQLite와 numpy로 직접 구현**했다. 수천 벡터는 브루트포스로 밀리초에 끝나고, 혼자 유지하는 코드에 추상화를 없으면 나중에 갇아야 한다
- 컬렉션마다 유사도 임계가 다르다. 짧은 문자열이 모인 컬렉션은 아무 질의에나 어느 정도 닮기 때문에, 하나의 임계값을 전 컬렉션에 쓰면 무관한 결과가 통과한다
- GPU가 붙은 것처럼 보였다. 가용성 확인은 통과하는데 컨텍스트 생성이 실패했고, 원인은 드라이버였다

42% → 83% 한국어 Recall@3	0.39 → 0.80 MRR	35분 → 21초 전량 인덱싱 (CPU→GPU)
--	---------------------------------------	--

모델 선정 근거가 업계 통념뿐이었다. 한글과 JSON과 PyQGIS 세 축으로 평가 하네스를 짜고 그 통념을 직접 잴다. 두 전제가 모두 뒤집혔다.

후보 모델 실측: 정확도 x 속도

모델	한글	JSON	PYQGIS	응답 속도
qwen2.5:7b (채택)	100%	100%	69%	3~4초
qwen3-vl:8b	100%	83%	94%	19~50초
EXAONE 3.5	100%	100%	19%	3~6초

- "7B는 한글을 코드 중간에 깨뜨린다"는 관찰이 코드에 우회 로직으로 박혀 있었다. 건어내고 재보니 세 모델 모두 100%였다. 주석에 박힌 관찰은 박힌 시점에 멈춰 있고, 우회는 남는데 이유는 사라진다
- "한국어 특화 모델이 유리하다"고 보고 EXAONE을 유력 후보로 뒀는데, 한국어 축에서는 동점이었고 코드 생성은 19%로 최하였다. 병목은 한국어가 아니라 도메인 지식이었다. 증상만 보고 고른 처방이 빗나간 것이다
- 모델을 재기 전에 하네스 결함 2건을 먼저 잡아야 했다. 정답 코드가 deprecated API를 요구해서 최신 방식이 오답 처리됐고 (25%에서 69%로 교정), JSON 강제 옵션이 특정 모델에서 빈 응답을 내 파싱 실패가 40/40이었다. 고치지 않았다면 배관 문제를 능력 부족으로 읽었을 것이다

규율 측정: LLM을 쓰지 않기로 한 결정

전 계층 공통

기능마다 LLM과 규칙과 사람을 실측으로 비교해 도입 범위를 정했다. 결과적으로는 넣지 않기로 판단한 쪽이 더 많았다. 기준은 데이터가 얼마나 많으냐가 아니라 입력에 신호가 있느냐였다. 입력에 없는 신호는 학습으로 만들 수 없다.

도입 판정: 전부 실측 근거가 있다

대상	판정	근거
이미지 기반 처분 판정	도입 철회	VLM exact-match 8%. 이미지에 없는 근거를 지어냈다. 판정기에서 스크리닝 필터로 역할을 줄였다
같은 과제, 규칙으로	규칙 채택	같은 실험에서 도출한 규칙 1건이 재현율 100%(208건). VLM은 37%였다

대상	판정	근거
이미지 → 지목 분류	부적합 확정	재측정 42.5%인데 다수결 기준선이 58%다. 모델을 키워도 기준선 아래였다
의견 자동 생성	규칙 채택	산문인 줄 알았던 필드가 닫힌 라벨이었다(길이 중앙값 11자). 생성 과제가 아니라 분류였고, 규칙이 88~91%
QGIS 다단계 제어	로컬 7B 천장	코드 중간에 한글이 깨지고 다단계 판단이 무너졌다. 하이브리드로 전환
파이프라인 오케스트레이션	LLM 채택	자연어를 검증된 명령으로 옮기는 번역은 7B가 이긴다. 실제 일은 결정적 코드가 한다

오케스트레이션은 번역에 가깝고, QGIS 컨트롤은 코드 생성과 다단계 판단을 요구한다. 7B는 앞쪽에서 이기고 뒤쪽에서 진다.

두 층을 같은 문제로 묶으면 한 모델로 둘 다 시도하다 둘 다 놓친다.

내가 짠 규칙도 측정 대상이다

- 근거가 약한 채로 넣었던 보정 규칙이 정밀도 37%로 전체 정확도를 깎고 있었다. 오류 분석으로 찾아내 제거하니 84%에서 88%로 올랐다
- 규칙 정확도를 단일 사업 400행으로 재고 있던 것을 발견하고 사업 단위 투표 방식으로 도출 로직을 교정했다. 행 단위로 세면 합산 착시가 생긴다
- 평가셋이 작을 때는 근소한 차이를 쫓지 않는다. 튜닝하려면 평가셋부터 키운다는 것을 원칙으로 뒀다

Stack 기술 스택

LANGUAGE	Python (PyQGIS, PyQt) · SQL
LLM	Ollama · 프롬프트 엔지니어링 · few-shot 설계 · 에이전트 루프 · 평가 하네스 설계
RAG	sentence-transformers (bge-m3) · 임베딩 벡터 검색 · BM25 하이브리드 · 검색 품질 측정
DATA	SQLite · MariaDB · MongoDB · openpyxl · pyshp · 스키마 설계 · 마이그레이션

GIS	QGIS 플러그인 개발 · 좌표계 변환 · 지리참조 · 렌더링 파이프라인 · SIFT / LoFTR 정합
기타	Git · Streamlit · 회귀 테스트 설계 · 코드리뷰 · 사내 배포 인프라

세 계층은 순서대로 만들어졌다. 도구를 먼저 만들지 않았으면 파이프라인에 연결할 것이 없었고, 파이프라인이 없었으면 LLM에게 시킬 일이 없었다.